Türkçe Ders Kayıtlarından Otomatik Ders Notu Üretimi: Konuşma Tanıma Hata Yayılımı Analizi

Demet Aşgaroğlu
Bölüm ve üniversite adı
e-posta adresi

***Özet*—Bu çalışma, Türkçe ders kayıtlarından otomatik ders notu üreten bir işlem hattında konuşma tanıma hatalarının özet ve soru üretimine nasıl yayıldığını incelemektedir. Hata ölçütü olarak WER ve CER'e ek olarak terim düzeyinde hata ölçen Terim Hata Oranı (THO) kullanılmaktadır. Veri kümesi 4 kanaldan CC BY lisanslı 24 video ve 12,46 saatten oluşur. Whisper small, medium ve large-v3 modelleri çalıştırılmış, özet ve soru baseline'ı yerel bir dil modeliyle kurulmuştur. 1 saatlik altın transkript üzerinde large-v3 için WER %14,9, THO %7,1 bulunmuştur; İngilizce terimlerin hata oranı Türkçe terimlerinkinin yaklaşık dört katıdır.**

***Anahtar Kelimeler*—otomatik konuşma tanıma, Whisper, hata yayılımı, code-switching, özetleme, soru üretimi, Türkçe**

I. GİRİŞ

Ders kayıtlarından otomatik ders notu üretimi iki aşamadan oluşur: ses önce otomatik konuşma tanıma (ASR) ile yazıya çevrilir, ardından bu yazıdan büyük dil modeliyle özet ve soru üretilir. İlk aşamadaki hatalar ikinci aşamanın girdisini doğrudan etkiler.

Türkçe teknik derslerde bu risk daha belirgindir, çünkü konuşmacılar Türkçe cümleler içinde sık sık İngilizce terim kullanır. Bir terimin yanlış tanınması toplam hata oranında küçük görünebilir, ancak dersin anlamını değiştirebilir.

Araştırma sorusu: Whisper'ın yaptığı hatalar, özellikle teknik terim hataları, üretilen özet ve soruların kalitesini ne ölçüde bozmaktadır?

II. PROBLEM TANIMI VE HİPOTEZLER

A. Hata Yayılımı

Hata yayılımı, ASR aşamasında oluşan bir hatanın sonraki adımlara, yani özet ve soru üretimine taşınmasıdır.

B. Terim Hata Oranı

Genel hata oranı, terimlerdeki bozulmayı ayrıca göstermez. Bu nedenle yalnızca terim sözlüğündeki kelimeleri ölçen THO kullanılmaktadır:

THO = yanlış tanınan terim sayısı / referanstaki toplam terim sayısı

Örneğin referansta 20 terim varsa ve bunların 5'i yanlış tanınmışsa THO = 5/20 = %25 olur. Hesaplamada şu kurallar uygulanır:

1) Tüm metriklerden önce metin küçük harfe çevrilir; noktalama ve apostrof kaldırılır. Türkçe I/ı ve İ/i dönüşümü korunur.
2) Terimler kökten eşleştirilir: "array'in" ve "array'i" aynı terimdir. Ek hataları THO'ya girmez; WER ve CER'de görünür.
3) Yazım varyantları sözlükte tanımlanır: "index" ve "indeks" doğru kabul edilir.
4) Silinen terim hata sayılır.
5) Fazladan yazılan terim THO'ya girmez, çünkü payda referans terimlerinden oluşur; WER'de ekleme hatası olarak görünür.

C. Code-Switching Problemi

Code-switching, Türkçe konuşurken İngilizce terim kullanılmasıdır. Tablo I bu durumun ASR çıktısında yol açabileceği hataları göstermektedir.

TABLO I. Code-Switching Hata Örnekleri

Referans	Whisper çıktısı	Model
discard	diskart	small, large-v3
ampersand	ampercent / sant	small, medium / large-v3
float	flowout	small
printf	pirin	small
ram'de	rende / remde	small / medium, large-v3
char	çar	üç model

Örnekler altın transkript bölümlerindeki gerçek Whisper çıktılarıdır.

D. Hipotezler

Vizede baseline metrikleriyle ön bulgu verilecek hipotezler:

H1: Code-switching içeren konuşma bölümlerinde THO, yalnızca Türkçe içeren bölümlere göre daha yüksektir.

H2: Whisper model boyutu arttıkça WER azalır; ancak THO'daki göreli iyileşme WER'dekinden daha sınırlı kalır.

Yöntemi bu raporda tanımlanan ve finalde test edilecek hipotezler:

H3: WER ve THO arttıkça üretilen özet ve soruların kalitesi düşer.

H4: Terim hataları, aynı oranda genel kelime hatasına kıyasla daha fazla kalite kaybına neden olur.

III. LİTERATÜR TARAMASI

A. Whisper ve Türkçe ASR

Whisper, internetteki seslerin transkriptlerini tahmin etmek üzere 680.000 saatlik çok dilli veriyle eğitilmiştir ve ince ayar

gerektirmeden standart veri kümelerinde iyi genelleme göstermiştir [1].

Türkçe ASR tarafında Mussakhojayeva vd., 218,2 saatlik açık bir Türkçe konuşma derlemesi sunmuş ve akraba Türk dilleriyle eğitilen çok dilli modellerin hata oranlarını düşürdüğünü göstermiştir [2]. Görmez, Türkçenin sondan eklemeli yapısının ASR'yi zorlaştırdığını belirtmiş ve dil modeli eklemenin WER ile CER'i düşürdüğünü raporlamıştır [3]. Safaya ve Erzin, 6.500 saatlik YouTube verisiyle ön eğitim yapmış, ancak modellerin aksan, argo ve arka plan gürültüsüne karşı henüz yeterince dayanıklı olmadığını bulmuştur [4]. Polat ve Oyucu ise altyazılar, mobil uygulama ve TBMM kayıtlarından derlem oluşturmuştur [5].

B. Code-Switching ve Alan Terimleri

Agro vd., uçtan uca ASR'de code-switching çalışmalarını sistematik olarak derlemiştir [6]. Yang vd., Whisper'ın Mandarin-İngilizce code-switching verisine uyarlanmasının performansı artırdığını göstermiştir [7]. Jin vd., teknik jargon içeren akademik konuşmalarda ASR modellerinin ince ayarsız daha kötü sonuç verdiğini, ince ayarın ise WER'i belirgin biçimde düşürdüğünü raporlamıştır [8]. Bu iki deneysel çalışma Türkçe-İngilizce ders konuşmasını ele almamaktadır.

C. ASR Hatalarının Sonraki Görevlere Etkisi

Shapira vd., transkript gürültüsünün farklı şiddet ve türlerdeki etkisini sistematik olarak inceleyen bir çerçeve önermiştir. Bulgularına göre görev modelleri belirli bir gürültü düzeyini tolere edebilmekte ve hata türlerinden farklı biçimde etkilenmektedir [9]. Bu çalışma, projenin yöntem açısından temel aldığı kaynaktır.

Lee vd., konuşma tanıma hatalarının makine ile okuduğunu anlama üzerinde çok yıkıcı bir etkisi olduğunu bulmuştur [10]. Nguyen ve Nguyen, ASR hatalarının örtük söylem ilişkisi tanıma başarımını anlamlı biçimde düşürdüğünü göstermiştir [11]. Feng vd., altı doğal dil anlama görevinde ASR hatasının etkisini gürültü, hata türü ve konuşmacıya göre incelemiştir [12]. Everson vd., büyük dil modellerine yalnızca en iyi hipotez yerine sözcük karışıklık ağları verilmesinin bu görevlerde başarımı artırdığını raporlamıştır [13]. Martucci vd., temiz transkriptleri ASR hatalarını taklit edecek şekilde yapay olarak bozarak çeviri sistemlerini güçlendirmiştir [14]. Chowdhury vd., Bengalce konuşma belgelerinde özetlerin okunabilirliğinin bozulmadığını, ancak transkripsiyon hatalarının özet kalitesini etkilediğini göstermiştir [15].

D. Konuşma ve Ders Özetleme

Rezazadegan vd., konuşma özetleme alanındaki 110 çalışmayı derlemiştir [16]. Lv vd., VideoLectures.NET videolarından 9.616 video ve 125.000 transkript-özet çifti içeren VT-SSum veri kümesini sunmuştur [17]. Gonzalez vd., GPT-3 gibi büyük dil modelleriyle üretilen ders özetlerinin video yanında gösterildiğinde öğrencilerin sınav başarısını artırdığını bulmuştur [18]. Türkçe tarafında Eğin ve Onan, Veri Yapıları ve Algoritmalar alanında 82 ders videosu ile 3.281 insan özeti içeren TR-EduVSum veri kümesini oluşturmuştur [19].

E. Soru Üretimi

Du vd., okuduğunu anlama için uçtan uca eğitilen dikkat tabanlı bir soru üretim modeli önermiştir [20]. Kurdi vd., eğitim amaçlı otomatik soru üretiminde 93 çalışmayı derlemiş ve değerlendirme ölçütlerinin uyumlaştırılması gerektiğini vurgulamıştır [21]. Akyon vd., mT5 ile Türkçe metinlerden soru üretmiş ve bunu bu alandaki ilk akademik çalışma olarak tanımlamıştır [22]. Ros vd., ders transkripti pencerelerinden öğrenci sorusu üretiminin uygulanabilirliğini T5 modelleriyle incelemiştir [23]. Arisoy vd., büyük dil modelleriyle üretilen soru-cevap çiftlerinin Türkçe konuşma verisini de içeren soru-cevap görevlerinde başarımı artırdığını göstermiştir [24].

F. Araştırma Boşluğu

İncelenen çalışmalar ASR hatalarının sonraki görevleri olumsuz etkileyebildiğini göstermektedir, ancak bu çalışmaların odağı Türkçe ders kayıtları değildir. Türkçe ders özetleme ve soru-cevap çalışmaları ise ASR hata yayılımını terim düzeyinde ölçmemektedir. Bu taramada, Türkçe ders kayıtlarında ASR hatalarının hem özet hem soru üretimine yayılımını terim düzeyinde ölçen bir çalışmaya rastlanmamıştır. Bu çalışma, bu boşluğu THO ile ele almayı amaçlamaktadır.

IV. VERİ

A. Ders Kayıtları

Veri kümesi 4 YouTube kanalından 24 Türkçe teknik ders videosundan oluşmaktadır; toplam süre 12,46 saattir. Konular veri yapıları, algoritmalar ve programlamadır. Adaylar Creative Commons filtresiyle 8 konu sorgusundan toplanmış (154 video), 10 dakikadan kısa videolar elenmiştir. YouTube'un otomatik dil etiketi ile açıklamalar incelenmiş, MIT dersinin Türkçe seslendirmesi olan kanallar ile İngilizce anlatımlar doğal code-switching içermediği için çıkarılmıştır. Lisans etiketi kanal sahibinin beyanıdır. Ses dosyaları depoda tutulmaz; video listesi ve indirme betiği paylaşılır.

TABLO II. Veri Kümesi ve Lisans Bilgileri

Kanal	Video	Süre (sa)	Lisans / Ayrım
Murat Özalp	17	6,53	CC BY / geliştirme
NEÜ Bilişim Topluluğu	3	1,52	CC BY / geliştirme
Recai Oktaş	2	3,53	CC BY / test
Berk Bayar	2	0,87	CC BY / test

B. Altın Transkript ve Düzeltme Kılavuzu

Dört videodan 15'er dakika olmak üzere 1 saatlik kayıt sesi dinlenerek elle düzeltilmiş ve altın transkript hazırlanmıştır: 80 bölüm × 45 saniye, 7214 kelime, 748 terim. Videolar Murat Özalp (geliştirme), Recai Oktaş ve Berk Bayar'ın iki dersidir (test); böylece altın transkriptin 45 dakikası test konuşmacılarından gelir. Başlangıç metni, Whisper'dan bağımsız olan YouTube otomatik altyazısıdır. Düzeltme kılavuza göre yapılmış, dolgu sesleri yazılmamış, İngilizce terimler özgün yazımıyla bırakılmıştır. NEÜ kaydı dinlenerek

de güvenilir biçimde yazılamadığından altın transkripte alınmamış, yerine Berk Bayar'ın ikinci dersi kullanılmıştır. Transkript tek kişi tarafından hazırlanmış, yorumlayıcılar arası uyum ölçülmemiştir.

Düzeltme kılavuzuna göre söylenen yazılır, konuşmacının hataları düzeltilmez. Dolgu sesleri ve yarım kalan kelimeler yazılmaz, tam tekrarlar yazılır. Sayılar yazıyla yazılır; metrik hesabından önce ASR çıktısındaki rakamlar da yazıya çevrilir. İngilizce terimler özgün yazımıyla ve ek apostrofla ayrılarak yazılır (array'in), Türkçeleşmiş kelimeler Türkçe kalır (fonksiyon). Düzeltme sırasında Whisper çıktısına bakılmaz, böylece referans değerlendirilen sistemden etkilenmez.

Altın transkript 30-60 saniyelik bölümlere ayrılır ve her bölüm code-switching varlığına göre etiketlenir. Özet ve soru üretiminde bu bölümler 5-10 dakikalık parçalarda birleştirilir.

C. Terim Sözlükleri

Sözlük hem İngilizce hem Türkçe terimleri içerir ve her terim bu dil bilgisiyle etiketlenir. Böylece yalnızca Türkçe bölümlerde de THO hesaplanabilir. Sözlükte 93 terim bulunur: 63 İngilizce, 30 Türkçe.

V. BASELINE VE DENEY DÜZENİ

A. Değerlendirme Metrikleri

Kelime hata oranı aşağıdaki gibi hesaplanır. S değiştirme, D silme, I ekleme, N ise referanstaki kelime sayısıdır:

$$WER = (S + D + I) / N$$

CER aynı hesabı karakter düzeyinde yapar. H2 için en küçük ve en büyük model arasındaki göreli iyileşme WER ve THO için ayrı hesaplanır:

$$İyileşme = (Hata_small - Hata_large) / Hata_small$$

B. Konuşma Tanıma Baseline'ı

Deneyler NVIDIA GeForce RTX 4060 (8 GB VRAM) üzerinde faster-whisper 1.2.1 (CTranslate2 4.8.5) ile yürütülmüştür. Modeller small, medium ve large-v3'tür; hesaplama türü float16, dil Türkçe, ışın genişliği 5'tir. Ses etkinliği filtresi ve kelime zamanları açık, önceki metne koşullama kapalıdır. Ayarlar üç modelde aynıdır. Yaklaşık işleme hızı gerçek zamanın small için 19,6, medium için 13,9, large-v3 için 10,4 katıdır; small ve medium koşularının bir bölümünde GPU başka bir işle paylaşılmıştır.

TABLO III. Altın Transkript Üzerinde Baseline Sonuçları

Model	WER (%)	CER (%)	THO (%)
small	20,0	7,4	13,4
medium	15,5	6,1	8,7
large-v3	14,9	6,4	7,1

C. Özet ve Soru Üretimi Baseline'ı

Referans metin ve üç Whisper çıktısından, en fazla 7,5 dakikalık parçalar için aynı model ve aynı promptla özet ve 3 soru üretilmiştir. Model, 4 bit nicemlenmiş Qwen3-4B'dir [27]; örnekleme kapalıdır, böylece aynı girdi aynı çıktıyı verir. İnsan özeti bulunmadığından referans metinden üretilen çıktı ölçüt alınır. Bu ölçüm mutlak kaliteyi değil, ASR hatasının yarattığı değişimi gösterir. Özet için Türkçe kelime ayırıcıyla ROUGE-1 ve ROUGE-2 [25] ile referans özetteki terimlerin korunma oranı, sorular için her üretilen sorunun en benzer referans sorusuna ROUGE-1 değeri hesaplanır. BERTScore [26] finalde eklenecektir.

TABLO IV. Özet ve Soru Baseline Sonuçları (Altın Transkript)

Model	ROUGE-1	ROUGE-2	Terim koruma	Soru benz.
small	0,502	0,288	0,768	0,268
medium	0,508	0,289	0,739	0,286
large-v3	0,549	0,347	0,838	0,170

D. Test Konuşmacıları

Finaldeki iyileştirmelerin tarafsız ölçülebilmesi için Recai Oktaş ve Berk Bayar kanalları test kümesine (4,40 saat) ayrılmıştır. İyileştirmeler Murat Özalp ve NEÜ kayıtları üzerinde (8,05 saat) ayarlanacaktır. Bir konuşmacı iki kümede birden yer almaz.

E. Hipotez Test Planı

H1: Bölümler code-switching varlığına göre etiketlenir ve iki grubun THO değerleri karşılaştırılır. 45 saniyelik bölümlerin çoğunda İngilizce terim bulunabileceğinden, aynı bölümlerdeki İngilizce ve Türkçe terimlerin THO'su ile İngilizce terim yoğunluğu yüksek ve düşük bölümler de karşılaştırılır. Farklar için bölüm düzeyinde yeniden örneklemeyle %95 güven aralığı verilir.

H2: Göreli iyileşme WER ve THO için karşılaştırılır.

H3: Özet ve soru kalitesi ayrı ölçülür; hata oranlarıyla ilişkisi bölüm bazında incelenir (örneğin Spearman korelasyonu).

H4: Altın transkriptin bir sürümünde yalnızca terimler, diğerinde aynı sayıda terim dışı kelime bozulur; aynı model ve promptla üretilen çıktılardaki kalite kaybı karşılaştırılır. Temiz transkripti yapay olarak bozma yaklaşımı [14] çalışmasına, hata türlerinin ayrı incelenmesi ise [9] çalışmasına dayanmaktadır.

VI. ÖN BULGULAR

Bulgular 1 saatlik ve tek kişinin hazırladığı altın transkripte dayandığından ön bulgu olarak sunulmaktadır. Tablo III'te model büyüdükçe WER ve THO düşmektedir. En büyük kazanç small'dan medium'a geçişte görülür; medium ile large-v3 arasında WER farkı 0,7 puandır ve CER large-v3'te medium'dan biraz yüksektir. Yalnızca test konuşmacılarında (45 dakika) large-v3 için WER %14,6, THO %6,4 olup tüm kümeye yakındır.

H1: 80 bölümün 71 tanesinde İngilizce terim bulunduğundan, yalnızca 9 bölüm kalan ilk planlanan karşılaştırma anlamlı biçimde yapılamamıştır. Aynı bölümlerde İngilizce terimlerin THO'su Türkçe terimlerden yüksektir: small için %21,9 ve %7,8, large-v3 için %13,1 ve %3,1 (fark 10,0 puan, %95 GA 5,3–15,3). İngilizce terim yoğunluğu yüksek ve düşük bölümler arasında ise anlamlı bir

fark görülmemiştir (large-v3 farkı 2,7 puan, %95 GA -1,6–7,7). Bu sonuç H1'i terim dili düzeyinde destekler, bölüm düzeyinde desteklemez.

H2: small'dan large-v3'e göreli iyileşme WER'de %25,7, THO'da %47,0 olmuştur (fark -21,3 puan, %95 GA -33,6–-7,6). Beklentinin aksine THO, WER'den daha fazla iyileşmiştir ve güven aralığı sıfırı içermez; H2 bu veride desteklenmemektedir. Büyük modelin kazancı en çok terimlerde görülmektedir. Kalan terim hatalarının çoğu char → çar gibi İngilizce terimin Türkçe okunuşuyla yazılmasıdır.

Özet ve soru baseline'ı: İşlem hattı tüm kaynaklarda çalışmaktadır. Tablo IV'te Whisper çıktısından üretilen özetin referans özete ROUGE-1 benzerliği small için 0,502, medium için 0,508, large-v3 için 0,549'tür; terim koruma oranları 0,768, 0,739 ve 0,838'tür. Özet benzerliği ve terim koruma en düşük hatalı transkriptte (large-v3) en yüksektir; bu, H3 yönünde bir ilk işarettir. Soru benzerliği ise large-v3'te düşmüştür (0,170); bu kaynakta model parça başına ortalama 1,75 soru üretmiş, istenen 3 soruya uymamıştır. Soru üretimi finalde iyileştirilecektir. Değerler 8 parçalık küçük bir örneklemden gelmektedir ve H3 için kanıt olarak yorumlanmamalıdır.

VII. SONUÇ VE FİNAL PLANI

Finalde H3 ve H4 test edilecek, H1 ve H2 daha geniş veriyle tekrarlanacak ve terim sözlüğüyle düzeltme gibi bir iyileştirmenin etkisi ölçülecektir. Vize aşamasında veri kümesi, lisans belgeleri, sözlük, 1 saatlik altın transkript, üç Whisper modeliyle çeviri, WER/CER/THO kodu ve özet-soru baseline'ı tamamlanmıştır. İlk bulgular İngilizce terimlerin Türkçe terimlerden belirgin biçimde daha sık hatalı yazıldığını göstermektedir.

Kod deposu: https://github.com/DemetAsgaroglu/turkce-ders-notu-asr

KAYNAKLAR

[1] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust speech recognition via large-scale weak supervision," in *Proc. ICML*, 2023, vol. 202, pp. 28492–28518.

[2] S. Mussakhojayeva, K. Dauletbek, R. Yeshpanov, and H. A. Varol, "Multilingual speech recognition for Turkic languages," *Information*, vol. 14, no. 2, art. no. 74, 2023, doi: 10.3390/info14020074.

[3] Y. Görmez, "Customized deep learning based Turkish automatic speech recognition system supported by language model," *PeerJ Comput. Sci.*, vol. 10, art. no. e1981, 2024, doi: 10.7717/peerj-cs.1981.

[4] A. Safaya and E. Erzin, "Experiments on Turkish ASR with self-supervised speech representation learning," 2022, arXiv:2210.07323.

[5] H. Polat and S. Oyucu, "Building a speech and text corpus of Turkish: Large corpus collection with initial speech recognition results," *Symmetry*, vol. 12, no. 2, art. no. 290, 2020, doi: 10.3390/sym12020290.

[6] M. T. Agro, A. Kulkarni, K. Kadaoui, Z. Talat, and H. Aldarmaki, "Code-switching in end-to-end automatic speech recognition: A systematic literature review," 2025, arXiv:2507.07741.

[7] Y. Yang, Y. Peng, X. Zhong, H. Huang, and E. S. Chng, "Adapting OpenAI's Whisper for speech recognition on code-switch Mandarin-English SEAME and ASRU2019 datasets," 2023, arXiv:2311.17382.

[8] S. Jin, D. Srirag, and A. Joshi, "PAREDA: A multi-accent speech dataset of natural language processing research discussions," 2026, arXiv:2605.17860.

[9] O. Shapira, S. Chazan, and A. D. N. Cohen, "Measuring the effect of transcription noise on downstream language understanding tasks," in *Proc. 63rd Annu. Meeting ACL*, 2025, pp. 29978–30004, doi: 10.18653/v1/2025.acl-long.1449.

[10] C.-H. Lee, S.-L. Wu, C.-L. Liu, and H.-Y. Lee, "Spoken SQuAD: A study of mitigating the impact of speech recognition errors on listening comprehension," in *Proc. Interspeech*, 2018, pp. 3459–3463, doi: 10.21437/Interspeech.2018-1714.

[11] L. T. Nguyen and D. Q. Nguyen, "Investigating the impact of ASR errors on spoken implicit discourse relation recognition," in *Proc. Workshop Transcript Understanding*, 2022, pp. 34–39.

[12] L. Feng, J. Yu, Y. Wang, S. Liu, D. Cai, and H. Zheng, "ASR-robust natural language understanding on ASR-GLUE dataset," in *Proc. Interspeech*, 2022, pp. 1101–1105, doi: 10.21437/Interspeech.2022-10097.

[13] K. Everson *et al.*, "Towards ASR robust spoken language understanding through in-context learning with word confusion networks," 2024, arXiv:2401.02921.

[14] G. Martucci, M. Cettolo, M. Negri, and M. Turchi, "Lexical modeling of ASR errors for robust speech translation," in *Proc. Interspeech*, 2021.

[15] P. Chowdhury, N. Sarkar, S. Nath, and U. Sharma, "Analyzing the effects of transcription errors on summary generation of Bengali spoken documents," *ACM Trans. Asian Low-Resour. Lang. Inf. Process.*, vol. 23, no. 9, pp. 1–28, 2024, doi: 10.1145/3678005.

[16] D. Rezazadegan *et al.*, "Automatic speech summarisation: A scoping review," 2020, arXiv:2008.11897.

[17] T. Lv, L. Cui, M. Vasilijevic, and F. Wei, "VT-SSum: A benchmark dataset for video transcript segmentation and summarization," 2021, arXiv:2106.05606.

[18] H. Gonzalez *et al.*, "Automatically generated summaries of video lectures may enhance students' learning experience," in *Proc. 18th Workshop Innovative Use NLP Building Educ. Appl.*, 2023, pp. 382–393, doi: 10.18653/v1/2023.bea-1.31.

[19] F. Eğin and A. Onan, "TR-EduVSum: A Turkish-focused dataset and consensus framework for educational video summarization," in *Proc. SIGTURK*, 2026, pp. 52–60.

[20] X. Du, J. Shao, and C. Cardie, "Learning to ask: Neural question generation for reading comprehension," in *Proc. 55th Annu. Meeting ACL*, 2017, pp. 1342–1352, doi: 10.18653/v1/P17-1123.

[21] G. Kurdi, J. Leo, B. Parsia, U. Sattler, and S. Al-Emari, "A systematic review of automatic question generation for educational purposes," *Int. J. Artif. Intell. Educ.*, vol. 30, no. 1, pp. 121–204, 2020, doi: 10.1007/s40593-019-00186-y.

[22] F. C. Akyon, D. Cavusoglu, C. Cengiz, S. O. Altinuc, and A. Temizel, "Automated question generation and question answering from Turkish texts," *Turkish J. Elect. Eng. Comput. Sci.*, vol. 30, no. 5, pp. 1931–1940, 2022, doi: 10.55730/1300-0632.3914.

[23] K. Ros, M. Jong, C. H. Chan, and C. Zhai, "Generation of student questions for inquiry-based learning," in *Proc. 15th Int. Conf. Natural Lang. Gener.*, 2022, pp. 186–195, doi: 10.18653/v1/2022.inlg-main.14.

[24] E. Arisoy, M. Unlu Menevse, Y. Manav, and A. Ozgur, "Evaluating large language models in data generation for low-resource scenarios: A case study on question answering," in *Proc. Interspeech*, 2025, pp. 1773–1777, doi: 10.21437/Interspeech.2025-1965.

[25] C.-Y. Lin, "ROUGE: A package for automatic evaluation of summaries," in *Text Summarization Branches Out*, 2004, pp. 74–81.

[26] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "BERTScore: Evaluating text generation with BERT," in *Proc. ICLR*, 2020, arXiv:1904.09675.

[27] A. Yang et al., "Qwen3 technical report," 2025, arXiv:2505.09388.